

Diseño y evaluación de un servicio inteligente de predicción de información de red en sistemas de Edge Computing

Luis Melero Jareño

Tutores: Gabriel Cebrián Márquez · Estefanía Coronado Calero




Tabla de contenidos



01 Planteamiento

El contexto tecnológico, el problema, el objetivo del trabajo y el ciclo de entrenamiento de los modelos predictivos

Planteamiento

MintEDGE

Metodología

Resultados

Conclusiones y
trabajo futuro



5G

Latencia, fiabilidad y capacidad



Edge Computing

Cómputo cerca del usuario



QoS dinámica

Depende de tráfico, movilidad y recursos



Predicción de red

Anticipa el comportamiento futuro

De la monitorización reactiva a la orquestación proactiva

La demanda de los usuarios en redes 5G y sistemas Edge Computing puede variar de forma rápida e impredecible

GESTIÓN REACTIVA

Observar estado actual



Actuar



Respuesta tardía ante la degradación

GESTIÓN PROACTIVA

Predecir estado futuro



Actuar antes



Actuación antes de la degradación

La clave es pasar de reaccionar a anticiparse

1



Análisis del estado del arte

5G, Edge Computing, KPIs/QoS y ML

2



Análisis del simulador MintEDGE

Arquitectura, módulos internos y
datos generados

OBJETIVO PRINCIPAL

**Diseñar, desarrollar y evaluar un
servicio inteligente de predicción
de parámetros de QoS en
sistemas de Edge Computing, en
el contexto de redes 5G, para
apoyar la gestión proactiva de
recursos**

3



Desarrollo del servicio predictivo

Predicción de indicadores de red a
partir de simulaciones

4




Validación experimental

Comparación de modelos por
precisión y eficiencia


De los datos de simulación a la predicción de QoS futura

Machine Learning (ML)



Aprendizaje desde datos

Deep Learning (DL)



Redes neuronales profundas

Nuestro caso:
Regresión supervisada
 $X(t) \rightarrow QoS(t+5)$



Datos



Preprocesado



División



Entrenamiento



Evaluación



Selección final

Modelos tabulares

Filas independientes

Variables explícitas

DT, RF, XGBoost, LightGBM




Modelos secuenciales

Ventanas temporales

Patrones en secuencia

LSTM, CNN



02 MintEDGE

El simulador que genera los datos de partida

Planteamiento

MintEDGE


Metodología

Resultados

Conclusiones y
trabajo futuro

MintEDGE: El simulador que genera los datos

MintEDGE proporciona un entorno controlado para simular usuarios, servicios, infraestructura Edge y orquestación de recursos.




- Modela movilidad, estaciones base, servicios y servidores Edge.
- El orquestador gestiona la asignación de recursos.
- Genera trazas temporales con métricas de tráfico, recursos y QoS.
- Servicios soportados: vehículos conectados, realidad aumentada y análisis de video.

Cada ejecución de MintEDGE genera un CSV que recoge, instante a instante, la evolución del sistema simulado.

settings.py → **simulación MintEDGE** → **CSV de resultados**

- **Configuración del escenario:** ciudad, proveedor, usuarios y vehículos.
- **Trazas temporales:** métricas registradas a lo largo de la simulación.
- **Salidas heterogéneas:** cada escenario produce un CSV con estructura y valores propios.



Idea clave: los CSV de MintEDGE son la materia prima del conjunto de datos predictivo.

03 Metodología

Flujo de trabajo, representación de datos y criterios de comparación

Planteamiento

MintEDGE

Metodología

Resultados

Conclusiones y
trabajo futuro

Los ficheros CSV de MintEDGE no pueden combinarse directamente porque cada escenario tiene una estructura distinta.

Problema inicial

- Cada ciudad y operador genera una topología distinta.
- El número de BS cambia entre escenarios.
- Las columnas dependen de la combinación **BS + servicio + métrica**.
- Resultado: distinta dimensionalidad.

Diagram showing three CSV files (Maastricht, Elburg, Enschede) being processed by a funnel and gear icon to create a homogeneous dataset.

CSV CSV Maastricht

Tiempo	BS_01	BS_02	...	BS_10
0	5	8	...	11
1	9	7	...	14
2	12	10	...	16
...	...	...	...	...

CSV CSV Elburg

Tiempo	BS_01	BS_02	...	BS_24
0	14	6	...	11
1	18	9	...	13
2	21	13	...	15
...	...	...	...	...

CSV CSV Enschede

Tiempo	BS_01	BS_02	...	BS_48
0	22	18	...	11
1	36	27	...	41
2	45	35	...	53
...	...	...	...	...

Solución aplicada


- Agregación estadística por estación base.
- Cálculo fila a fila en cada instante de simulación.
- Estadísticos: **media, desviación típica, máximo, percentil 95...**
- Resultado: mismo espacio de características.

Conjunto de datos homogéneo ✓

NUM_BS	peticiones totales	media retardo	media energía	usuarios totales
10	96	12.4	4.3	28
10	122	10.1	3.7	31
...	...	...	...	...
24	230	11.6	4.1	59
24	289	9.5	3.5	63
...	...	...	...	...
48	472	13.2	4.8	116
48	603	10.3	3.9	123
...	...	...	...	...

Para entrenar modelos predictivos, todos los escenarios deben compartir el mismo espacio de características

A partir del conjunto homogéneo se crean variables adicionales para capturar mejor la dinámica del sistema.



No solo se homogeneizan los CSV; también se construyen variables más informativas para el aprendizaje.

Variable objetivo: tasa futura de peticiones satisfechas

Predicción de QoS futura a partir de datos alineados



tasa de peticiones satisfechas sobre peticiones aceptadas

`satisfied_rate_over_accepted(t+5)`



Normalizada



Interpretable



Útil para orquestación

global

connected_vehicles

augmented_reality

video_analysis

Dependiendo del tipo de modelo, se sigue una estrategia de partición

70% → Entrenamiento
10% → Validación
20% → Prueba

Conjunto de datos preparado
Muestras de varios escenarios



Shuffle


Orden temporal

Filas independientes



Modelos tabulares
70/10/20 con shuffle

Secuencias continuas



Modelos secuenciales
Bloques temporales por ciudad

Demasiadas variables → **Ruido y redundancia**



Solución

Reducir redundancia
y conservar variables
más informativas

Métodos de selección

Pearson

Spearman

Kendall

f_regression

CFS


TOP 5

TOP 10


TOP 20

SOLO SOBRE ENTRENAMIENTO
Evitar filtración a validación y prueba

- Secuenciales sin variables temporales explícitas
- Temporalidad por ventanas

Comparación de modelos clásicos y *gradient boosting*

Decisiones metodológicas y comparación de arquitecturas secuenciales



Una vez obtenidos los resultados de
predicción sobre validación...



¿Cómo elegimos el mejor modelo?


R²

Más alto mejor
Peso=**0.6**



MAE

Más bajo mejor
Peso=**0.3**



Tiempo de inferencia

Más bajo mejor
Peso=**0.1**



score

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

$$score = 0.6 * R^2 - 0.3 * MAE_{norm} - 0.1 * t_{norm}$$

Se prioriza precisión y penaliza
error y tiempo de inferencia

04 Resultados

Selección en validación y evaluación final en prueba

Planteamiento

MintEDGE


Metodología

Resultados


Conclusiones y
trabajo futuro

El **score** selecciona el mejor modelo por variable objetivo

global




connected_vehicles




LightGBM obtiene el mayor score en las variables objetivo más estables

El **score** selecciona el mejor modelo por variable objetivo

augmented_reality



video_analysis



XGBoost obtiene el mayor score en las variables objetivo más irregulares

Ventanas temporales → CNN / LSTM → Score en validación

global
CNN filters=256

$R^2 = 0.9884$
MAE = 0.0183
t = 0.115070

score = **0.5154**

connected_vehicles
CNN filters=32

$R^2 = 0.9889$
MAE = 0.0191
t = 0.076216

score = **0.5861**

augmented_reality
CNN filters=32

$R^2 = 0.7244$
MAE = 0.0870
t = 0.092148

score = **0.3736**

video_analysisis
CNN filters=32

$R^2 = 0.8186$
MAE = 0.0004
t = 0.034715


score = **0.4912**

CNN

- ⚡ Menor tiempo de inferencia
- ✓ Mayor score debido a esto

LSTM

- 🧠 Memoria temporal
- 🕒 Mayor coste computacional
- =
- 🐢 Mayor tiempo de inferencia



GLOBAL									
	tipo	modelo	seleccion	hiperpar.	R ²	MAE	RMSE	ms/muestra	score
1	Tabular	LightGBM	Pearson top20	num_leaves=128	0.9943	0.0115	0.0192	0.000562	0.5966
2	Secuencial	CNN	pearson_top10	filters=256	0.9884	0.0183	0.0257	0.115070	0.1930
Ganador: LightGBM Pearson top20 num_leaves=128 R ² =0.9943 MAE=0.0115 0.000562 ms/m score=0.5966									
CONNECTED VEHICLES									
	tipo	modelo	seleccion	hiperpar.	R ²	MAE	RMSE	ms/muestra	score
1	Tabular	LightGBM	Kendall top10	num_leaves=64	0.9939	0.0133	0.0249	0.000485	0.5963
2	Secuencial	CNN	pearson_top10	filters=32	0.9889	0.0191	0.0324	0.076216	0.1933
Ganador: LightGBM Kendall top10 num_leaves=64 R ² =0.9939 MAE=0.0133 0.000485 ms/m score=0.5963									
AUGMENTED REALITY									
	tipo	modelo	seleccion	hiperpar.	R ²	MAE	RMSE	ms/muestra	score
1	Tabular	XGBoost	Spearman top20	n_estimators=200	0.7540	0.0859	0.1274	0.000401	0.4524
2	Secuencial	CNN	pearson_top5	filters=32	0.7244	0.0870	0.1293	0.092148	0.0346
Ganador: XGBoost Spearman top20 n_estimators=200 R ² =0.7540 MAE=0.0859 0.000401 ms/m score=0.4524									
VIDEO ANALYSIS									
	tipo	modelo	seleccion	hiperpar.	R ²	MAE	RMSE	ms/muestra	score
1	Tabular	XGBoost	Spearman top20	n_estimators=100	0.8323	0.0004	0.0014	0.000107	0.4994
2	Secuencial	CNN	cfs_top5	filters=32	0.8186	0.0004	0.0014	0.034715	0.3912
Ganador: XGBoost Spearman top20 n_estimators=100 R ² =0.8323 MAE=0.0004 0.000107 ms/m score=0.4994									

GANADORES

global → **LightGBM (num_leaves=128)**
 connected_vehicles → **LightGBM (num_leaves=64)**
 augmented_reality → **XGBoost (n_estimators=200)**
 video_analysis → **XGBoost (n_estimators=100)**

Mejor equilibrio global

↑ precisión

↓ error

↓ tiempo de inferencia



**Los modelos tabulares dominan
frente a los secuenciales**

Los modelos ganadores mantienen su rendimiento en datos no vistos

GLOBAL

Modelo	Selección	Hiperpar.	R ² _val	R ² _test	Δ R ²	MAE_val	MAE_test	Δ MAE	RMSE_val	RMSE_test	ms/muestra
LightGBM	Pearson top20	num_leaves=128	0.9943	0.9943	+0.0000	0.0115	0.0115	+0.0000	0.0192	0.0193	0.001641

CONNECTED VEHICLES

Modelo	Selección	Hiperpar.	R ² _val	R ² _test	Δ R ²	MAE_val	MAE_test	Δ MAE	RMSE_val	RMSE_test	ms/muestra
LightGBM	Kendall top10	num_leaves=64	0.9939	0.9941	+0.0002	0.0133	0.0133	+0.0000	0.0249	0.0247	0.001000

AUGMENTED REALITY

Modelo	Selección	Hiperpar.	R ² _val	R ² _test	Δ R ²	MAE_val	MAE_test	Δ MAE	RMSE_val	RMSE_test	ms/muestra
XGBoost	Spearman top20	n_estimators=200	0.7540	0.7562	+0.0022	0.0859	0.0858	-0.0001	0.1274	0.1270	0.000506

VIDEO ANALYSIS

Modelo	Selección	Hiperpar.	R ² _val	R ² _test	Δ R ²	MAE_val	MAE_test	Δ MAE	RMSE_val	RMSE_test	ms/muestra
XGBoost	Spearman top20	n_estimators=100	0.8323	0.8285	-0.0038	0.0004	0.0004	+0.0000	0.0014	0.0014	0.000290


✓ Validación ≈ prueba

✓ Sin caída relevante de rendimiento

✓ Modelos finalistas generalizan correctamente

Conjunto de prueba confirma robustez de los modelos seleccionados

Predictores seleccionados y preparados para su uso posterior



Evaluación en prueba → Selección final → **Guardado .pkl**

Resultado final: cuatro modelos preparados para futura integración en MintEDGE

05 Conclusiones

Aportaciones, limitaciones y trabajo futuro

Planteamiento


MintEDGE

Metodología



Resultados

Conclusiones y
trabajo futuro

CONCLUSIONES

Flujo
completoDataset
homogéneoModelos
ganadoresGeneralización
en prueba

TRABAJO FUTURO

Integración en
MintEDGEOrquestación
proactivaAmpliar
escenarios

Datos reales




Se ha cumplido el objetivo principal: diseñar y evaluar un servicio predictivo de QoS para sistemas Edge Computing.

¡Gracias por su atención!




¿Alguna pregunta?

Algunas métricas de QoS se registraban instante después de las peticiones que las originaban.



Como resultado obtenemos unas tasas de QoS coherentes para el entrenamiento predictivo

Los modelos finales reproducen la evolución de la QoS futura



✓ Ajuste muy alto en objetivos estables

✓ Mayor dificultad en objetivos irregulares

✓ Predicción útil para anticipar QoS

Las predicciones siguen la tendencia real, aunque las variables objetivo más irregulares presentan mayor dificultad.